01 / VISÃO EXECUTIVA

Da experimentação à esteira de vídeos com IA

Quatro pautas concluídas. A evolução está no processo, nos componentes e na qualidade das decisões.

4 pautas • 4,88 min

Série B, Raphinha e dois episódios de Entre a Taça e a Degola. Versões da mesma pauta não são novos vídeos.

15% menos tempo

EP02 versus EP01: soma dos períodos de execução do agente. Inclui ferramentas e renderização; não mede horas humanas.

Tokens não caíram

EP02 usou 74% mais tokens totais que EP01. O contexto acumulado cresceu; rapidez e consumo são métricas diferentes.

A tese para a gestão: investir no sistema reutilizável e medir cada etapa.

Resultados observacionais de quatro pautas, sem experimento controlado. Não há fatura individual por vídeo disponível.

02 / CURVA DE APRENDIZADO

O que aprendemos e transformamos em processo

A direção do usuário virou regras, componentes e verificações que permanecem disponíveis para a próxima pauta.

Série B

Construir a base

Identidade, tipografia, diagramas, trilha e exportação vertical. A revisão V2 virou referência.

Raphinha

Ampliar a linguagem

Recortes, papel, ações de bola e timeline. Troca de locução mostrou a importância de separar arte e tempos.

EP01

Organizar a série

Pastas por episódio, escudos nos gráficos, aprovação de telas e biblioteca de encerramento.

EP02

Reaproveitar e ajustar

Mesma lógica gráfica; montagem pela nova voz, pulsos pela música e dados incompletos tratados explicitamente.

Aprendizado operacional documentado nos arquivos de revisão e montagem. Reutilização não elimina criação, análise de dados ou revisão humana.

03 / COMPARAÇÃO MEDIDA

O tempo melhora; o escopo explica as diferenças

Soma do início ao fim dos turnos concluídos atribuídos a cada pauta.

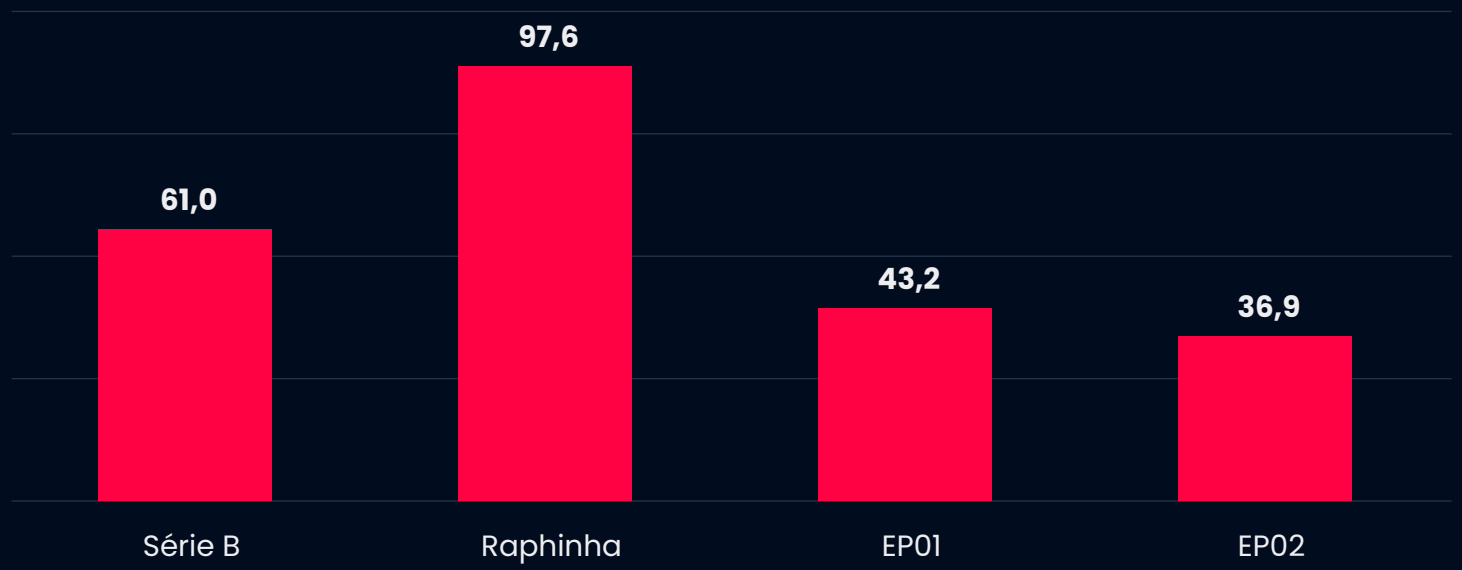

Minutos por minuto de vídeo

Série B 73,5 min/min

Raphinha 47,6 min/min

EP01 43,4 min/min

EP02 36,8 min/min

Raphinha: V1 levou 21,2 min na etapa final. O ciclo completo, com telas e V2/V3, levou 97,6 min.

Duração final: Série B 49,8s; Raphinha 123s; EP01 59,7s; EP02 60,1s. Tempos excluem os intervalos entre turnos e não equivalem a horas de uma pessoa.

04 / TOKENS E MODELOS

Mais contexto pode anular a economia de tempo

Tokens totais = entrada + saída. A entrada em cache é parte da entrada, não uma categoria adicional a somar.

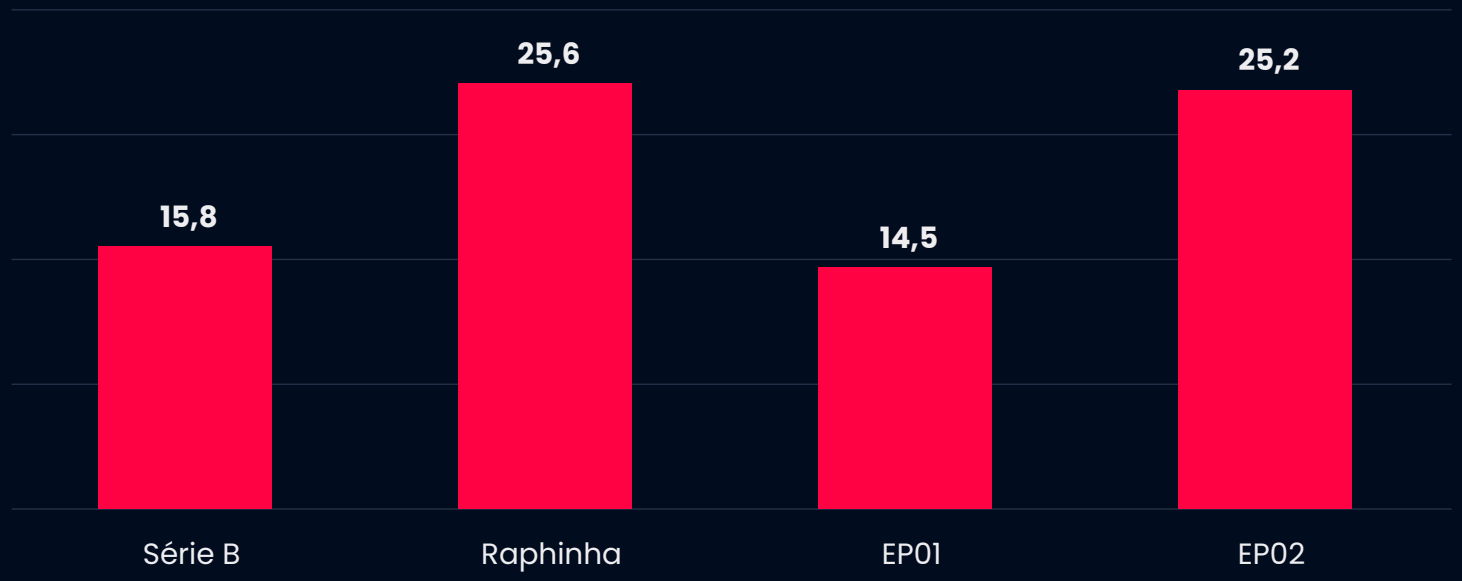

Cache na entrada: Série B 97,5% • Raphinha 98,2% • EP01 98,7% • EP02 98,5%

Modelos registrados

Série B / EP01 / EP02
gpt-6.1-sol

Raphinha
gpt-6.1-sol + gpt-6-astra
(Astra na criação das telas)

Raphinha: Astra representa 12% dos tokens e 56% dos créditos simulados.

Não há teste que isole o efeito do modelo. Atribuir a melhoria apenas a “uma IA melhor” não é sustentado pelos registros. Modelos de revisão automática ficam fora desta análise.

05 / CONSUMO PONDERADO

Tokens iguais podem ter pesos diferentes

Estimativa em créditos equivalentes Standard: aplica as tarifas atuais ao consumo registrado, por modelo e categoria.

Pauta	Tempo[1]	Tokens	Modelo(s)	Créditos[2]
Série B	61,0 min	15,78 M	Sol	86,2
Raphinha	97,6 min	25,57 M	Sol + Astra	244,1
EP01	43,2 min	14,49 M	Sol	67,6
EP02	36,9 min	25,18 M	Sol	98,3

Tarifas por 1 milhão: Sol = 50 / 2,5 / 250; Astra = 250 / 25 / 1.250 créditos.
Ordem: entrada sem cache / entrada em cache / saída.

[1] Tempo de execução do agente. [2] Simulação Standard a preços de consulta (13/11/2026), não débito histórico nem fatura. Não inclui ElevenLabs, imagem, máquina ou trabalho humano. Fonte: learn.chatgpt.com/docs/pricing

06 / OPORTUNIDADES

O próximo ganho está no briefing e no contexto

A velocidade observada é compatível com reutilização. A causalidade e o ganho de cada ação ainda precisam ser medidos.

Fechar os dados antes

EP02: a trajetória do Z4 exigiu esclarecimentos. Pedir tabela por rodada no briefing evita reconstruções durante a montagem.

Levar só o necessário

Nova sessão por pauta com resumo aprovado e biblioteca compartilhada. Hipótese: menos reenvio de histórico sem perder identidade.

Rotear pelo trabalho

Manter o modelo já validado como base. Testar opções mais leves em tarefas mecânicas; reservar raciocínio complexo para dados e direção.

O aprendizado foi converter feedback em memória do projeto, não depender da memória da conversa.

Custo monetário real por vídeo: não apurado. Para fechar o ROI, incluir plano/fatura, ElevenLabs, imagens, renderização, horas humanas e desempenho das publicações.

07 / PROJEÇÃO CONDICIONAL

Planejar escala com faixas, sem prometer uma curva

Referência: média de EP01 e EP02 para episódios próximos de 60s, com voz e fotos disponíveis.

Base por episódio

40,0 min de execução
82,9 créditos equivalentes

Faixa observada (n = 2)
36,9–43,2 min
67,6–98,3 créditos

Meta de -20% é hipótese de planejamento, não tendência ajustada nem intervalo estatístico. Para 10 episódios: base 829 créditos; cenário -20% 664. Pressupõe reduzir o consumo ponderado em 20%, sem mudar modelo, tarifas ou escopo.

08 / DECISÃO E MÉTODO

Escalar o processo; instrumentar o próximo ciclo

Recomendação: um piloto de cinco novos episódios com briefing completo e métricas por etapa.

Medir

Telas • revisões • montagem • exportação.
Tokens por modelo/categoria, tempo do agente, espera do usuário e horas humanas separadas.

Comparar

Custo por minuto aprovado e publicado.
Testar o mesmo briefing em modelos diferentes, com o mesmo padrão de qualidade e limite de revisões.

Decidir

Expandir se o ganho se repetir.
A biblioteca é um ativo reutilizável; a direção editorial humana segue sendo responsável por pauta, dados e aprovação.

Base auditável: metricas.csv + metricas.json. Sem transcrições privadas no material executivo.

Método: registros locais de 10–13/11/2026; respostas únicas por response_id, por turno/modelo. Exclui revisão automática, GitHub, consolidação de manuais e esta apresentação. Janela completa e cortes constam na base.